

Байесовские SRGAN

Егор Крашенинников

Физико-техническая школа СПбАУ НОЦНТ РАН

Научный руководитель: Александр Сироткин

E-mail: krashennikovvegor@gmail.com.

1 Введение

1.1 Классические GAN

Генеративные состязательные сети (GANs), впервые представленные Яном Гудфеллоу в 2014 году [1], находят применение в задачах генерации искусственных данных. GAN состоит из двух моделей – генератора G и дискриминатора D . Генератор пытается создавать примеры как можно более похожие на реальные, а дискриминатор – как можно лучше отличать реальные примеры от сгенерированных. Несмотря на всю эффективность GAN-ов, их обучение часто ведет к так называемым *mode collapses*, когда генератор просто запоминает несколько примеров, чтобы обмануть дискриминатор. Эта проблема по своей сути очень похожа на переобучение, которое возникает из-за того, что оптимизируя какую-то функцию правдоподобия, мы пытаемся найти параметры модели, при которых достигается её максимум. Но с точки зрения здравого смысла найти максимум функции правдоподобия – значит переобучить модель, и в GAN это проявляется особенно остро.

1.2 Байесовские GAN

Насколько мы знаем, Юнус Саатчи и Эндрю Гордон Вильсон первыми представили детализированную Байесовскую интерпретацию GAN [2]. Они утверждают, что она способна избежать *mode collapses*, а также, что методы Байеса позволяют добиться более высокой генерализации модели и превзойти классическую версию. В своей работе они вводят априорные распределения на параметры генератора и дискриминатора, а маргинализацию апостериорных распределений над этими параметрами совершают, используя стохастические градиенты НМС (Hamiltonian Monte Carlo) [3].

2 Байесовские SRGAN

Одной из задач, в которой классические GAN-ы добились больших успехов, является задача увеличения разрешения изображений [4]. Мы предлагаем использовать

недавно представленные Байесовские GAN для большей натурализации генерируемых изображений повышенного разрешения. Иными словами, наша цель – сделать генератор более естественным.

2.1 Метод

Имея набор изображений \mathcal{D} , допустим, что I^{LR} – зашумленное нормальным шумом изображение пониженного разрешения, полученное в результате применения перечисленных операций к соответствующей I^{HR} , $I^{HR} \in \mathcal{D}$. Введем генератор и дискриминатор, как $G(I^{LR}; \theta_g)$ и $D(C; \theta_d)$, параметризованные θ_g и θ_d соответственно; $\theta_g \sim p(\theta_g)$, $\theta_d \sim p(\theta_d)$, C принимает значения либо I^{HR} , либо $G(I^{LR}; \theta_g)$, в зависимости от тренировочного шага. Объявив распределения над распределениями параметров, мы получаем континуум всех возможных генераторов и дискриминаторов и в дальнейшем будем маргинализировать апостериорные распределения над θ_g и θ_d , пользуясь сэмплингом Монте-Карло и следующими формулировками:

$$p(\theta_g | X, \theta_d) \propto \left(\prod_{i=1}^n D(G(I_i^{LR}; \theta_g); \theta_d) \right) p(\theta_g | \alpha_g)$$

$$p(\theta_d | X, \theta_g) \propto \prod_{i=1}^n D(I_i^{HR}; \theta_d) \times \prod_{i=1}^n (1 - D(G(I_i^{LR}; \theta_g); \theta_d)) \times p(\theta_d | \alpha_d),$$

где $X = \{I_i^{LR}, I_i^{HR}\}_{i=1}^n$ – набор из n тренировочных примеров, а α_g и α_d – соответствующие гиперпараметры априорных распределений.

Список литературы

- [1] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair et al., *Generative Adversarial Networks*, *ArXiv e-prints* (2014) [1406.2661].
- [2] Y. Saatchi and A. G. Wilson, *Bayesian GAN*, *ArXiv e-prints* (2017) [1705.09558].
- [3] T. Chen, E. B. Fox and C. Guestrin, *Stochastic Gradient Hamiltonian Monte Carlo*, *ArXiv e-prints* (2014) [1402.4102].
- [4] C. Ledig, L. Theis, F. Huszar, J. Caballero, A. Cunningham, A. Acosta et al., *Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network*, *ArXiv e-prints* (2016) [1609.04802].